Uczenie ze wzmocnieniem

(Reinforcement Learning)

Materiały dodatkowe

- Richard S. Sutton and Andrew G. Barto, *Reinforcement learning, an introduction,* second edition:

  http://incompleteideas.net/book/the-book-2nd.html

- David Silver, *UCL Course on RL:*

  http://www0.cs.ucl.ac.uk/staff/d.silver/web/Teaching.html

Wstęp

- 3 podstawowe podejścia do uczenia maszynowego:
  - Uczenie nadzorowane
  - Uczenie nienadzorowane
  - Uczenie ze wzmocnieniem

Wstęp

- 3 podstawowe podejścia do uczenia maszynowego:
  - Uczenie nadzorowane
  - Uczenie nienadzorowane
  - Uczenie ze wzmocnieniem
- Inspiracje:
  - Sieci neuronowe – budowa układu nerwowego żywych organizmów.
  - Uczenie ze wzmocnieniem – podejście behawioralne do uczenia.

Wstęp

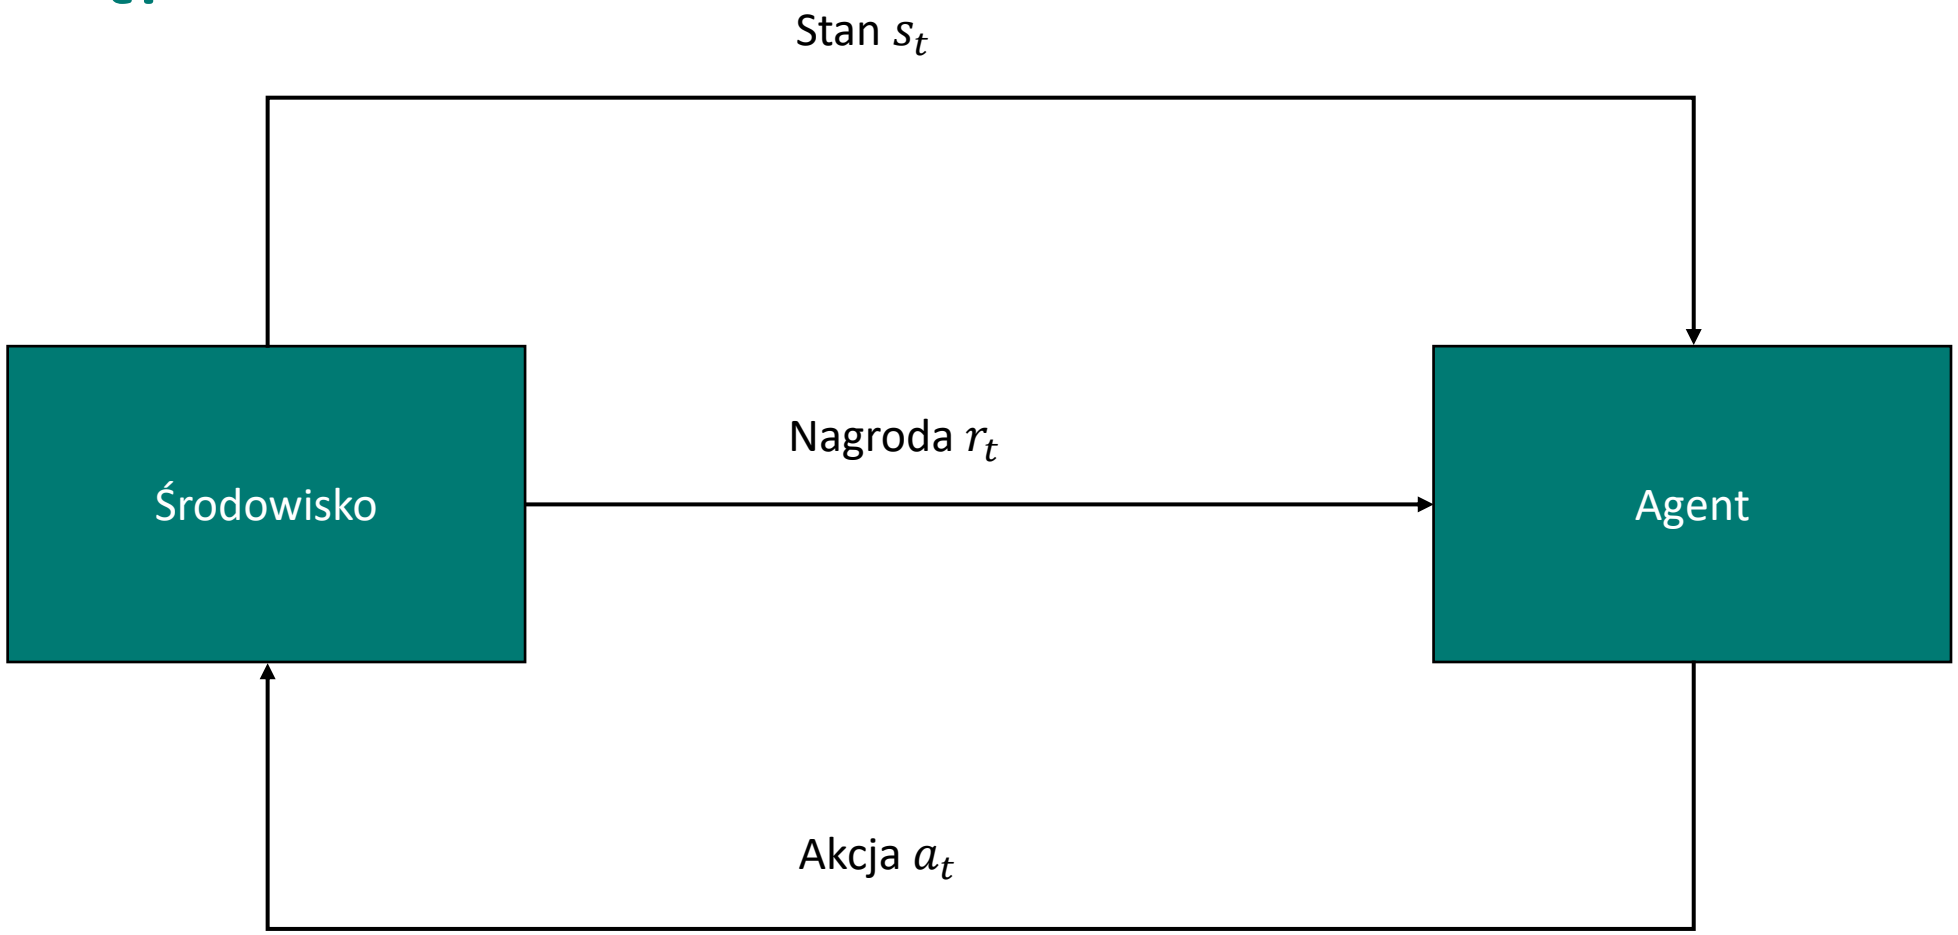

Wstęp

Hipoteza nagrody - celem agenta jest maksymalizacja wartości oczekiwanej jego skumulowanej użyteczności.

Łańcuch Markowa

- Ciąg zdarzeń, w którym prawdopodobieństwo każdego zdarzenia zależy jedynie od wyniku poprzedniego

$$P(X_{n+1} \leqslant y | X_0, X_1, X_2, \ldots, X_n) = P(X_{n+1} \leqslant y | X_n)$$

Łańcuch Markowa

- Ciąg zdarzeń, w którym prawdopodobieństwo każdego zdarzenia zależy jedynie od wyniku poprzedniego

$$P(X_{n+1} \leqslant y | X_0, X_1, X_2, \ldots, X_n) = P(X_{n+1} \leqslant y | X_n)$$

- **Własność Markowa** – warunkowe rozkłady prawdopodobieństwa przyszłych stanów procesu są zdeterminowane wyłącznie przez jego bieżący stan, bez względu na przeszłość.

Łańcuch Markowa

- Przykład – gra w Rosyjską ruletkę:

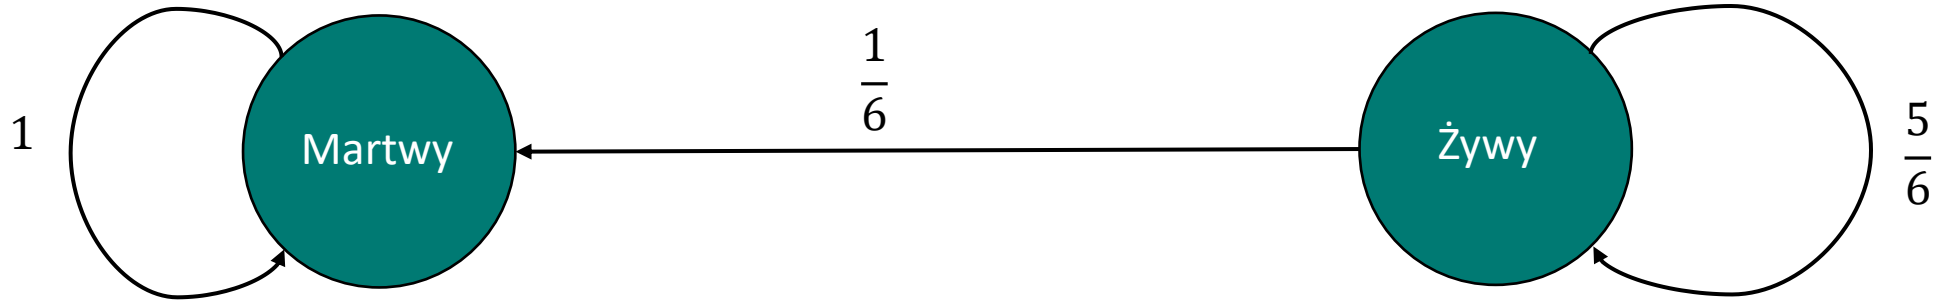

- Macierz przejścia:

$$P = \begin{bmatrix} 1 & 0 \\ \frac{1}{6} & \frac{5}{6} \end{bmatrix}$$

Łańcuch Markowa

- Macierz:

$$P^{(n)} = \begin{bmatrix} p_{11}^{(n)} & \cdots & p_{1n}^{(n)} \\ \vdots & \ddots & \vdots \\ p_{n1}^{(n)} & \cdots & p_{nn}^{(n)} \end{bmatrix}$$

nazywamy macierzą przejść.

- Gdy prawdopodobieństwa nie zależą od aktualnego stanu mówimy, że łańcuch jest jednorodny.

$$P = \begin{bmatrix} p_{11} & \cdots & p_{1n} \\ \vdots & \ddots & \vdots \\ p_{n1} & \cdots & p_{nn} \end{bmatrix}$$

Przykład

Monopoly

- Monopoly to jedna z najpopularniejszych gier planszowych w historii; jej historia sięga lat 30 XX wieku.
- Spróbujmy przedstawić ją jako łańcuch Markowa.
- Badamy tylko poruszanie się, na razie nie uwzględniamy decyzji graczy.

Przykład

Monopoly

- Gracze rzucają dwiema sześciennymi kostkami i przesuwa swój pionek o ilość pół, którą wyrzucił kostkami.
- Dla uproszczenia pomińmy zasady związane z dubletami (taką samą liczbę oczek na obu kostkach) - wyraźnie uprości to grę (dlaczego?).

Przykład

Monopoly

- Dodatkowo interesują nas jedynie karty typu „Kasa Społeczna”.
  - Takich kart jest **16**; 1 cofa gracza na **początek**, 1 wysyła go do **więzienia**, pozostałe nie mają wpływu na jego pozycję.
  - Karty typu „Szansa” nie zmieniają wyników a byłyby uciążliwe do zakodowania ;)

Proces Markowa z nagrodami

- Proces Markowa z nagrodami (*Markov reward process* – MRP) definiujemy jako następującą krotkę $(\boldsymbol{S}, \boldsymbol{P}, \boldsymbol{R}, \boldsymbol{\beta})$:
  - $\boldsymbol{S}$ – jest skończonym zbiorem stanów.
  - $\boldsymbol{P}(\mathbf{s}, \mathbf{s}')$– Prawdopodobieństwo znalezienia się w stanie $\mathbf{s}'$ w czasie $t + 1$ pod warunkiem znajdowania się w stanie s w czasie t.
  - $\boldsymbol{R}(\mathbf{s}, \mathbf{s}')$ – Nagroda za przejście ze stanu s do stanu $\mathbf{s}'$ w czasie t.
  - $\boldsymbol{\beta}$ – współczynnik dyskontujący $\beta \in [0,1)$

Proces Markowa z nagrodami

- Skumulowana przyszła nagroda:

$$R_t = r_{t+1} + \beta r_{t+2} + \cdots + \beta^{\mathrm{T}-1} r_{\mathrm{T}-t} = \sum_{k=1}^{\mathrm{T}-\mathrm{t}} \beta^{k-1} r_{t+k}$$

- **Funkcję wartości** $V(s)$ definiujemy jako oczekiwaną wypłatę zaczynając od stanu s

$$V(s) = E[R_t | S_t = s]$$

Równanie Bellmana

- Oba równania można zdekomponować do postaci natychmiastowej nagrody i zdyskontowanej przyszłej wartości:

$$V(s) = E[R_t|S_t = s] = E[r_{t+1} + \beta V(S_{t+1})|S_t = s]$$

Taka postać nosi nazwę **Równania Bellmana**

Przykład

$\boldsymbol{\beta = 1}$

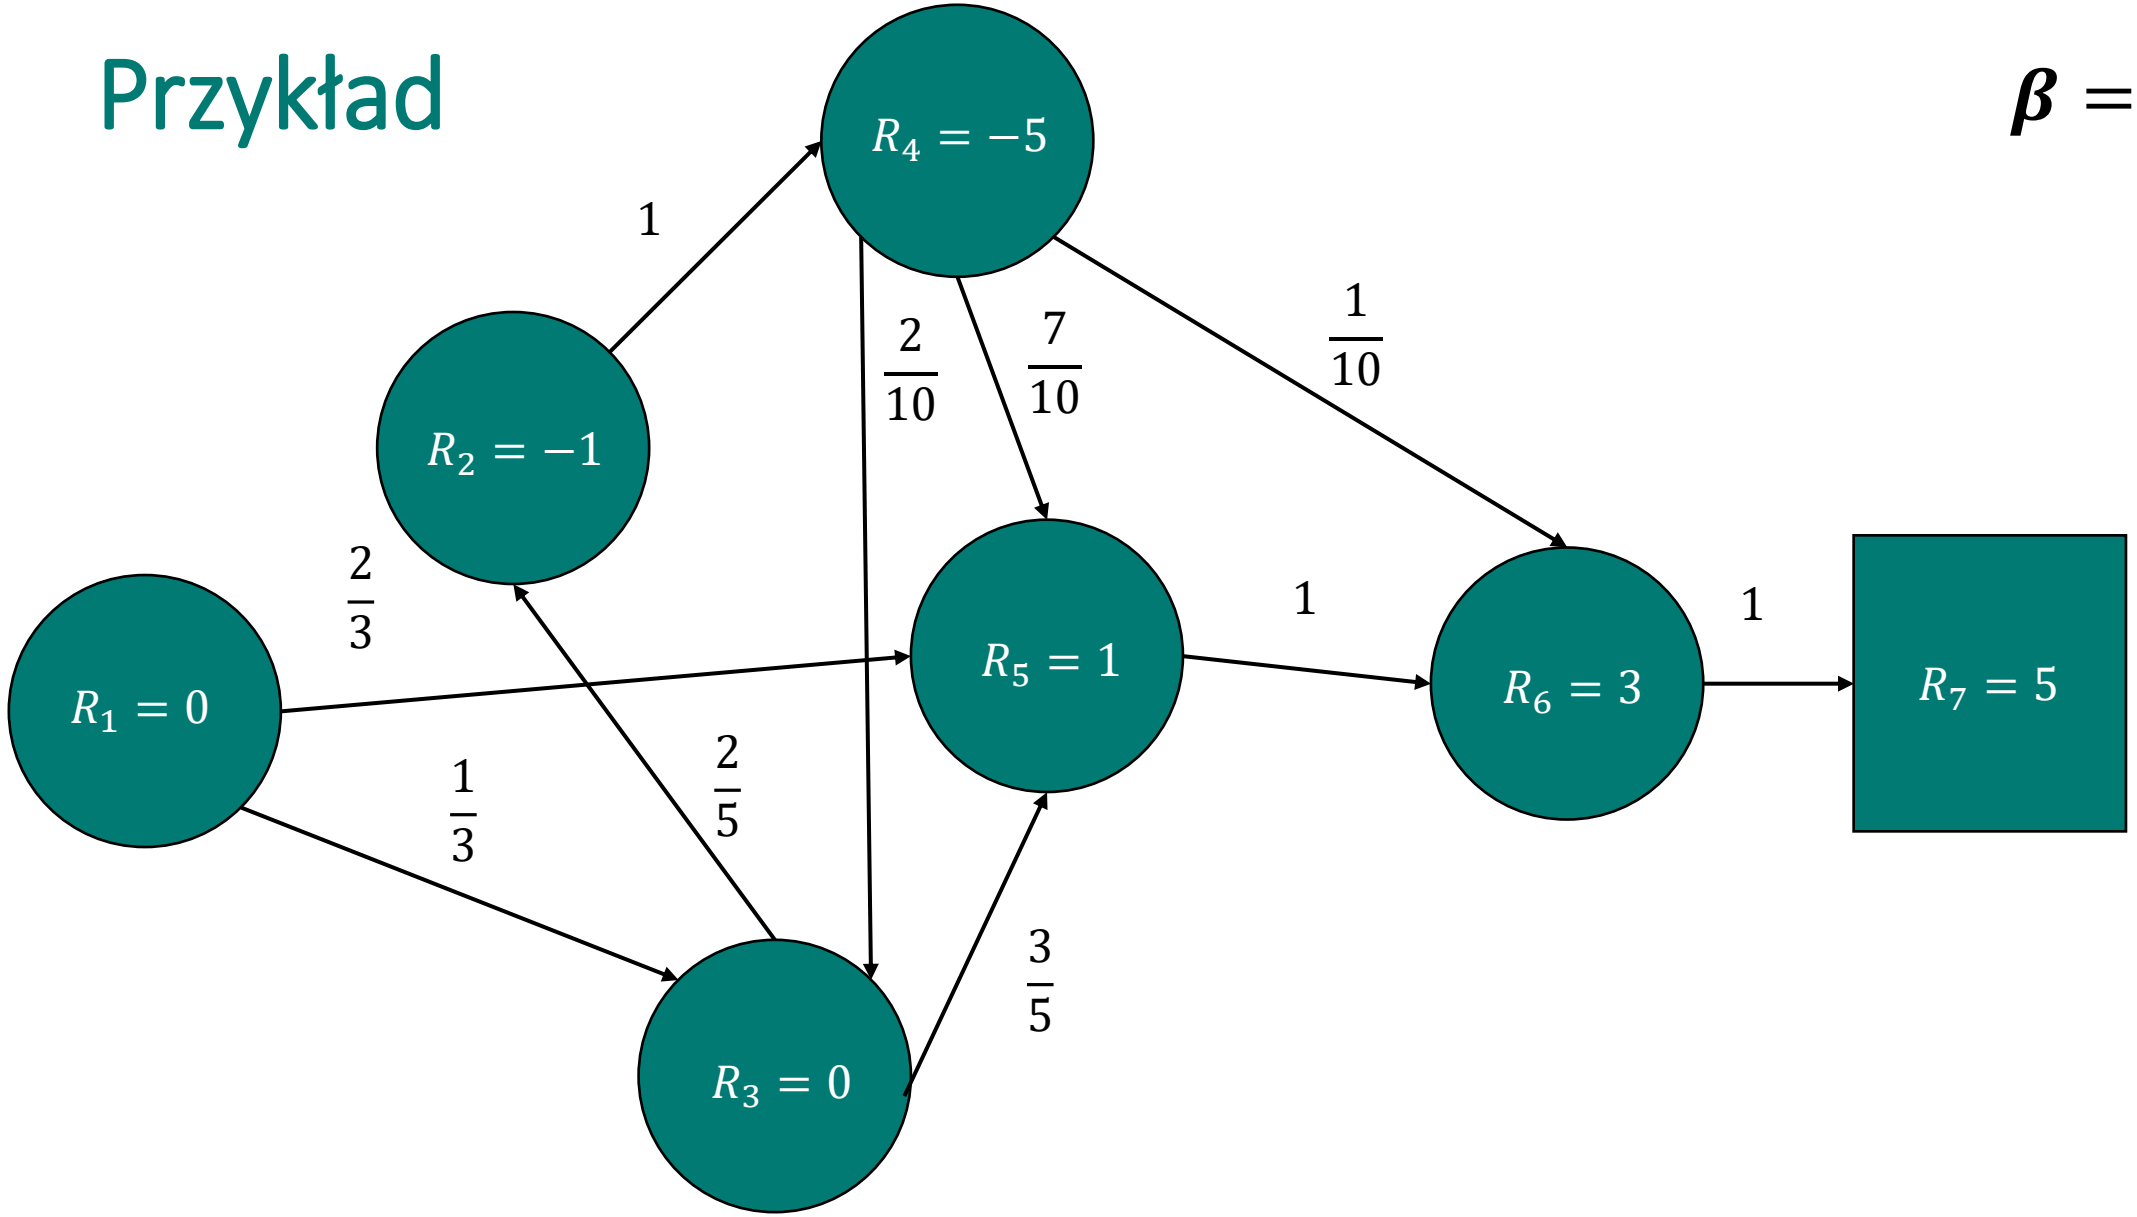

Proces decyzyjny Markowa

- Proces decyzyjny Markowa (*Markov decision process* – MDP) definiujemy jako następującą krotkę $(\boldsymbol{S}, \boldsymbol{A}, \boldsymbol{P}, \boldsymbol{R}, \boldsymbol{\beta})$:
  - $\boldsymbol{S}$ – jest skończonym zbiorem stanów.
  - $\boldsymbol{A}$ – jest skończonym zbiorem akcji.
  - $\boldsymbol{P}(\mathbf{s}, \mathbf{a}, \mathbf{s}')$– Prawdopodobieństwo znalezienia się w stanie $\mathbf{s}'$ w czasie $t + 1$ w wyniku podjęcia działania a w stanie s w czasie t.
  - $\boldsymbol{R}(\mathbf{s}, \mathbf{a}, \mathbf{s}')$ – Nagroda za przejście ze stanu s do stanu $\mathbf{s}'$ wyniku podjęcia działania a w czasie t.
  - $\boldsymbol{\beta}$ – współczynnik dyskontujący $\beta \in [0,1)$

Proces decyzyjny Markowa

- Proces decyzyjny Markowa (*Markov decision process* – MDP) definiujemy jako następującą krotkę $(\boldsymbol{S}, \boldsymbol{A}, \boldsymbol{P}, \boldsymbol{R}, \boldsymbol{\beta})$:
  - $\boldsymbol{S}$ – jest skończonym zbiorem stanów.
  - $\boldsymbol{A}$ – jest skończonym zbiorem akcji.
  - $\boldsymbol{P}(\mathbf{s}, \mathbf{a}, \mathbf{s}')$– Prawdopodobieństwo znalezienia się w stanie $\mathbf{s}'$ w czasie $t+1$ w wyniku podjęcia działania a w stanie s w czasie t.
  - $\mathbf{R}(\mathbf{s}, \mathbf{a}, \mathbf{s}')$ – Nagroda za przejście ze stanu s do stanu $\mathbf{s}'$ wyniku podjęcia działania a w czasie t.
  - $\boldsymbol{\beta}$ – współczynnik dyskontujący $\beta \in [0,1)$

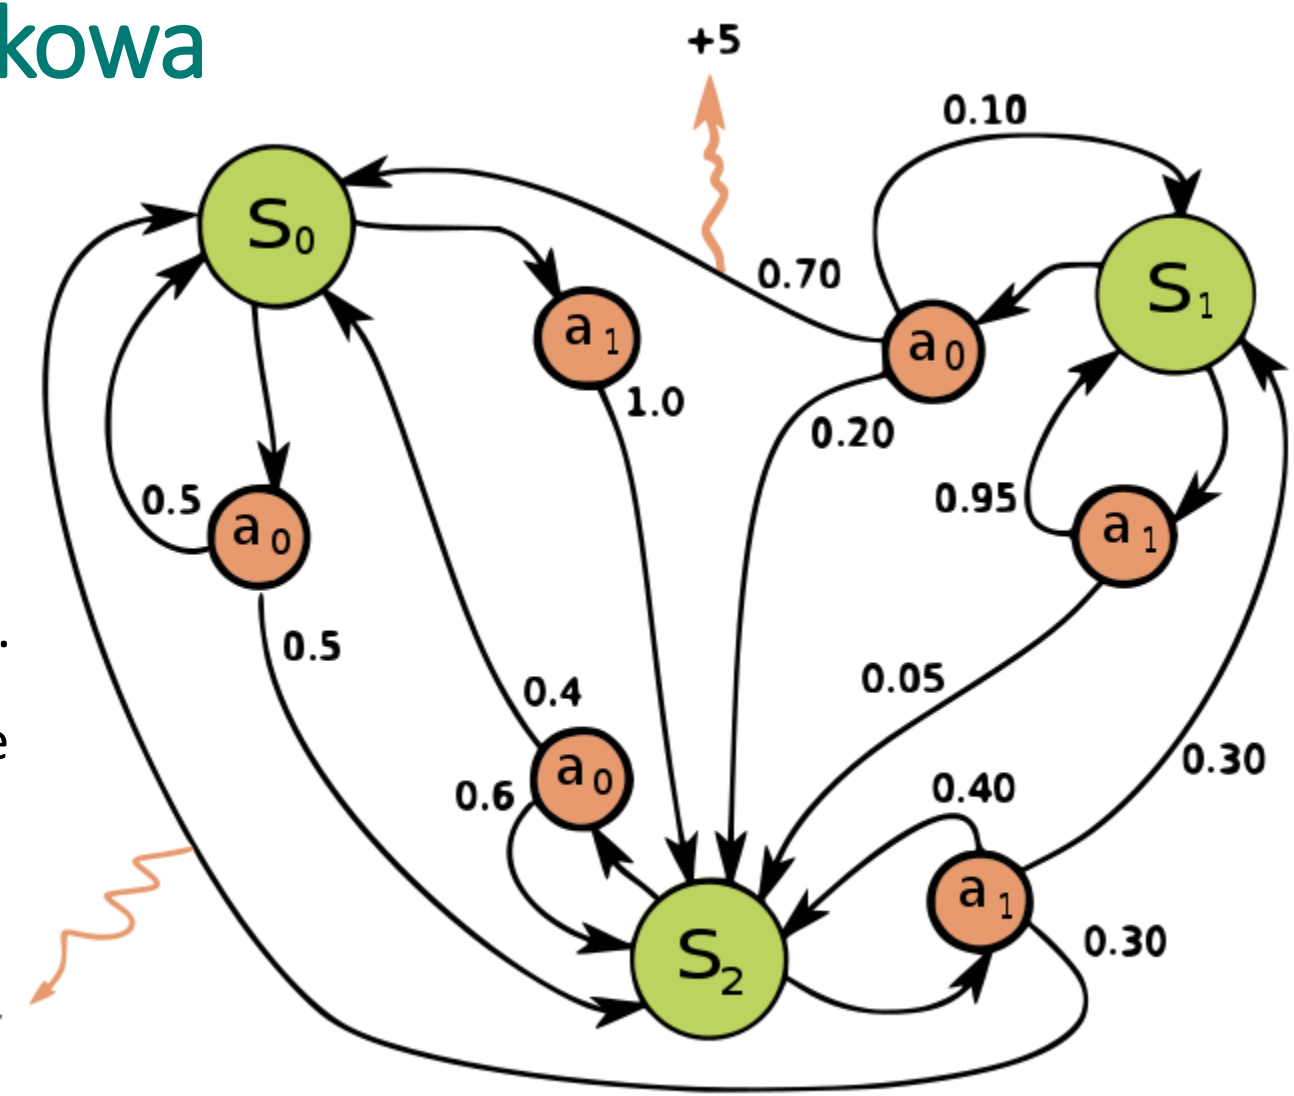

Proces decyzyjny Markowa

- **Strategię** definiujemy jako:

$$\pi\colon S \to A$$
$$\pi(a|s) = \ P[A_t = a|S_t = s]$$

- Strategia w pełni opisuje zachowania agenta.
- Strategie zależą jedynie od aktualnego stanu MDP a nie od historii.
- Są *stacjonarne* (nie zależą od czasu).

Proces decyzyjny Markowa

- **Funkcję wartości stanu** *(state-value function)* $V_\pi(s)$ definiujemy jako oczekiwaną wypłatę zaczynając od stanu s i podążając za strategią π:

$$V_\pi(s) = E_\pi[R_t|S_t = s]$$

- **Funkcję wartości akcji** *(action-value function)* $q_\pi(s, a)$ definiujemy jako oczekiwaną wypłatę zaczynając od stanu s, podejmując akcję a i podążając za strategią π:

$$q_\pi(s, a) = E_\pi[R_t|S_t = s \mid A_t = a]$$

Równanie Bellmana

- Oba równania można zdekomponować do postaci natychmiastowej nagrody i zdyskontowanej przyszłej wartości:

$$V_\pi(s) = E_\pi[R_t|S_t = s] = E_\pi[r_{t+1} + \beta V_\pi(S_{t+1})|S_t = s]$$

$$q_\pi(s,a) = E_\pi[R_t|S_t = s \mid A_t = a] = E_\pi[r_{t+1} + \beta q_\pi(S_{t+1}, A_{t+1})|S_t = s \mid A_t = a]$$

Taka postać nosi nazwę **Równania Bellmana**

Równanie Bellmana

- Upraszczając możemy zapisać oba równania w formie:
  - $V_\pi(s) = R(s) + \beta P(s, \pi(s), s')V_\pi(s')$
  - $q_\pi(s, \pi(s)) = R(s) + \beta P(s, \pi(s), s')q_\pi(s', \pi(s'))$

Proces decyzyjny Markowa

- **Optymalna funkcja wartości stanu** V_***:**

$$V_*(s) = \max_{\pi} V_\pi(s, a)$$

- **Optymalna funkcja wartości akcji** $q_*(s, a)$**:**

$$q_*(s, a) = \max_{\pi} q_\pi(s, a)$$

Równanie Bellmana

- Dla każdego problemu, który można zdefiniować jako proces decyzyjny Markowa:
  - istnieje taka optymalna, deterministyczna strategia π_*, która jest nie gorsza od pozostałych dostępnych $\pi_*(s) \geq \pi(s),\ \forall\pi\ \ \forall s \in S$
  - Optymalna strategia π_* osiąga optymalną wartość funkcji wartości $V_{\pi_*}(s) = V_*(s).$
  - Optymalna strategia π_* osiąga optymalną wartość funkcji wartości akcji $q_{\pi_*}(s,a) = q_*(s,a).$

Równanie Bellmana

- Definiujemy ją jako:

$$\pi_*(s|a) = \begin{cases} 1 \;\; gdy \; a = \underset{a \in A}{\operatorname{argmax}} \, q_*(s,a) \\ 0 \; w \; przeciwnym \; wypadku \end{cases}$$

- Aby ją znaleźć musimy znaleźć maksymalizować po $q_*(s,a)$.
- Gdy znamy $q_*(s,a)$ znalezienie optymalnej strategii jest trywialne.

Wyszukiwanie wyczerpujące

Exhaustive search

- Równania Bellmana można rozwiązać analitycznie.
- Złożoność obliczeniowa sięga $\mathrm{O}(\mathrm{n}^3)$ gdzie n oznacza liczbę stanów.
- W przypadku rozwiązywania dużych problemów istnieje wiele metod iteracyjnych:
  - Exhaustive search
  - Programowanie dynamiczne
  - Metody Monte Carlo
  - Temporal Difference Learning

Przykład

Skoczek na szachownicy

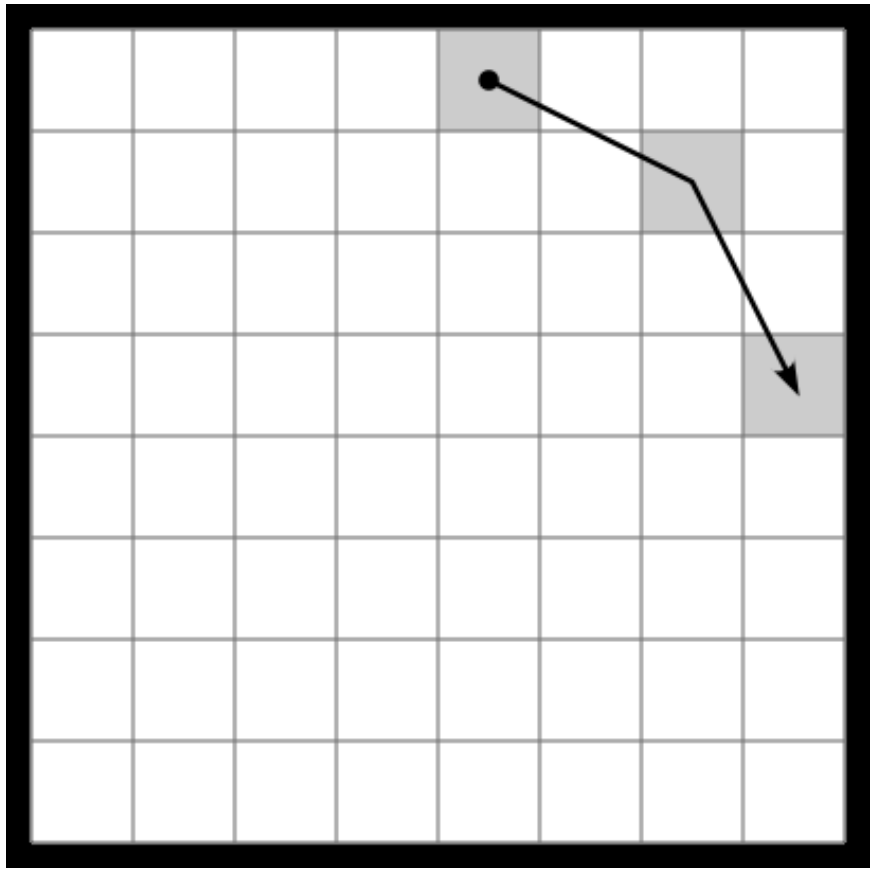

- Celem jest obejście skoczkiem wszystkich pól planszy tak, żeby na każdym polu stanąć raz i tylko raz.

Exhaustive search

- Np. backtracking
- Metody nieefektywne – wymagają przechowywania dużej ilości informacji:

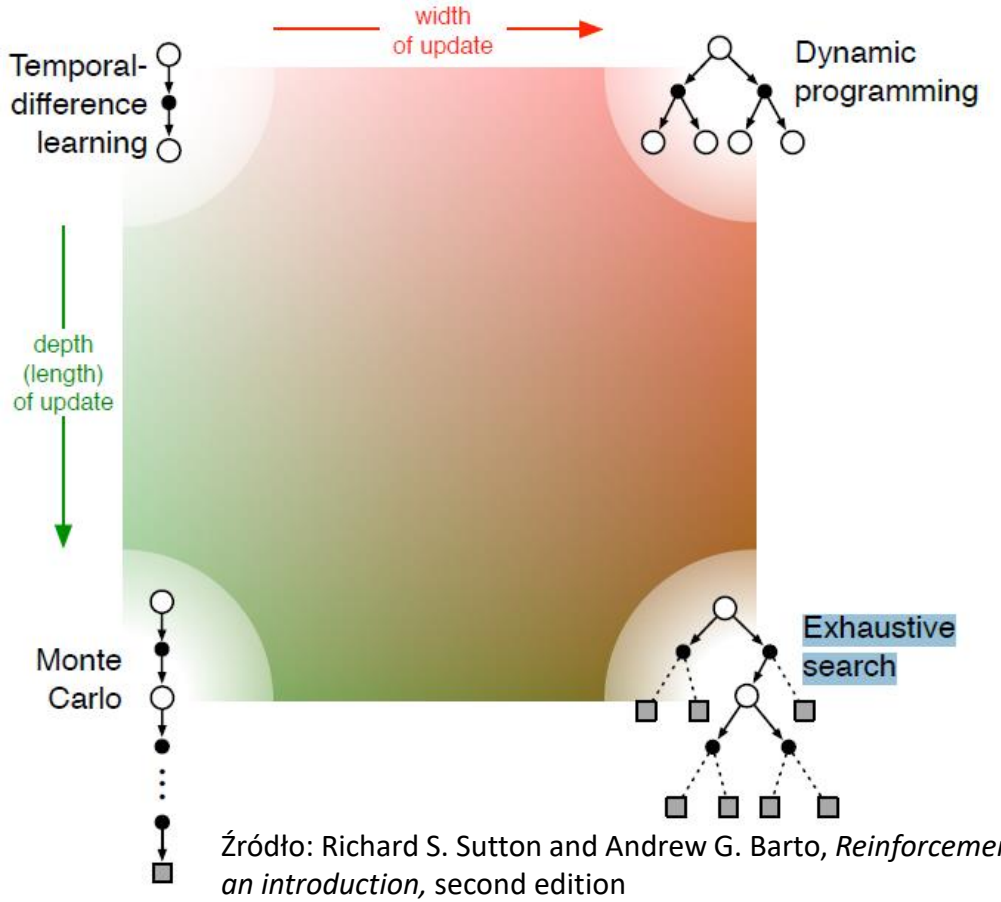

Źródło: Richard S. Sutton and Andrew G. Barto, *Reinforcement learning, an introduction,* second edition